



北京交通大学

BEIJING JIAOTONG UNIVERSITY



智能信息技术教育中心

The Education Center of Intelligence Information Technologies

人工智能基础

机器学习

耿阳李敖
2022年3月



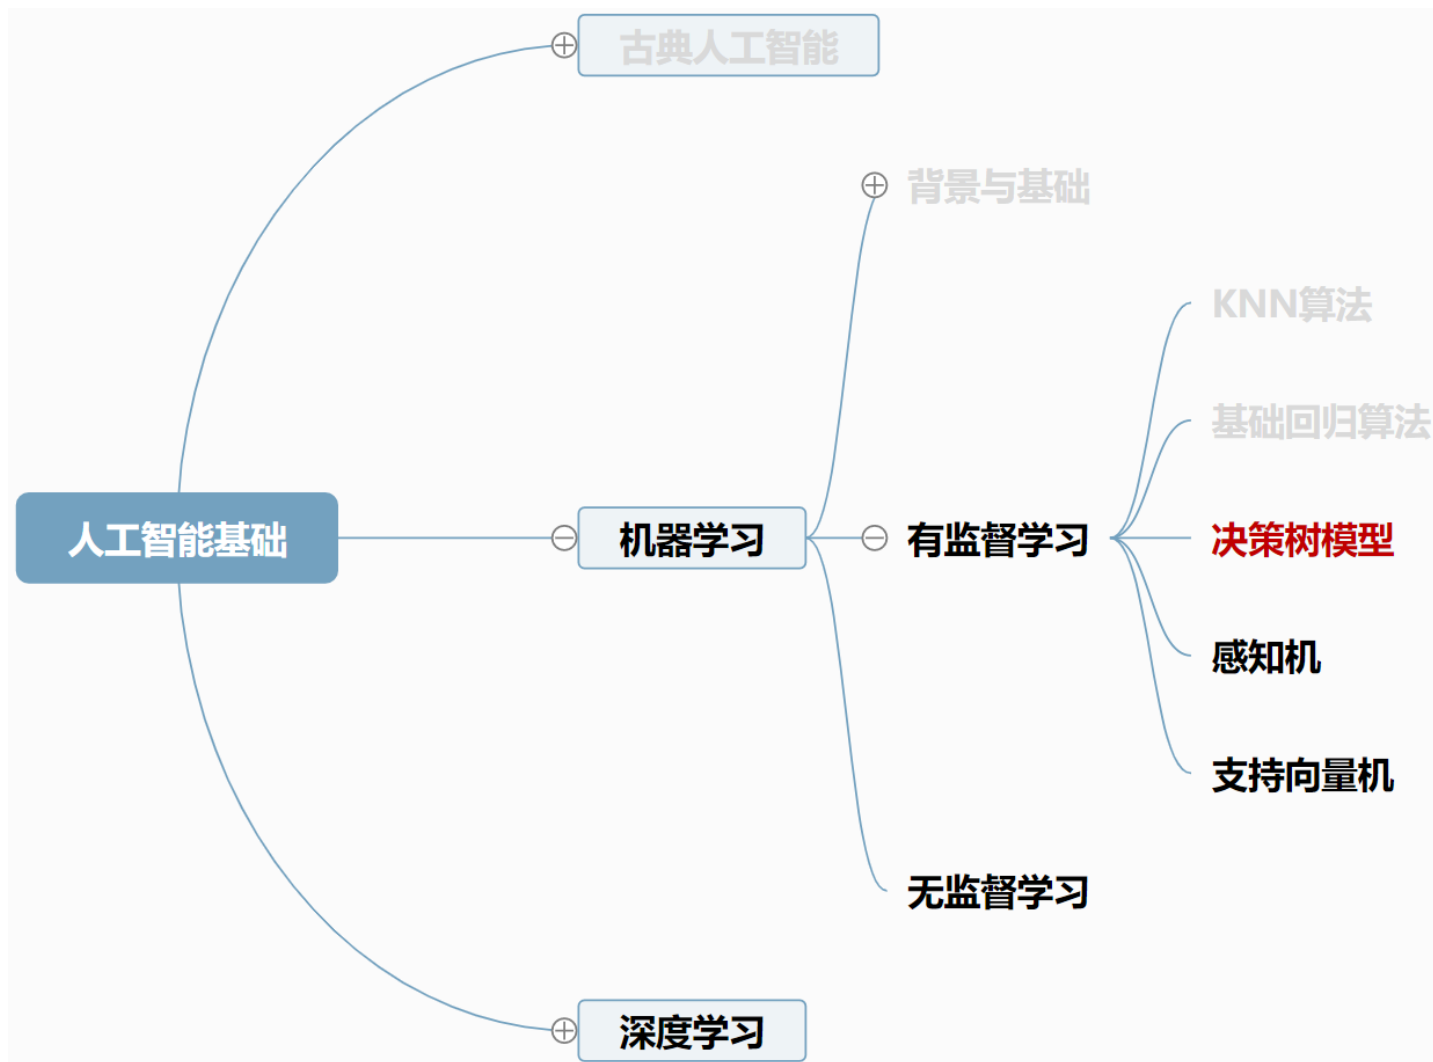
课程反馈

- ◆ 讲授内容过难，数学内容多
- ◆ 课堂缺乏互动
- ◆ 作业
- ◆ 节课方式

内容概要

- **内容回顾**
- 感知机
- 支持向量机
- 总结

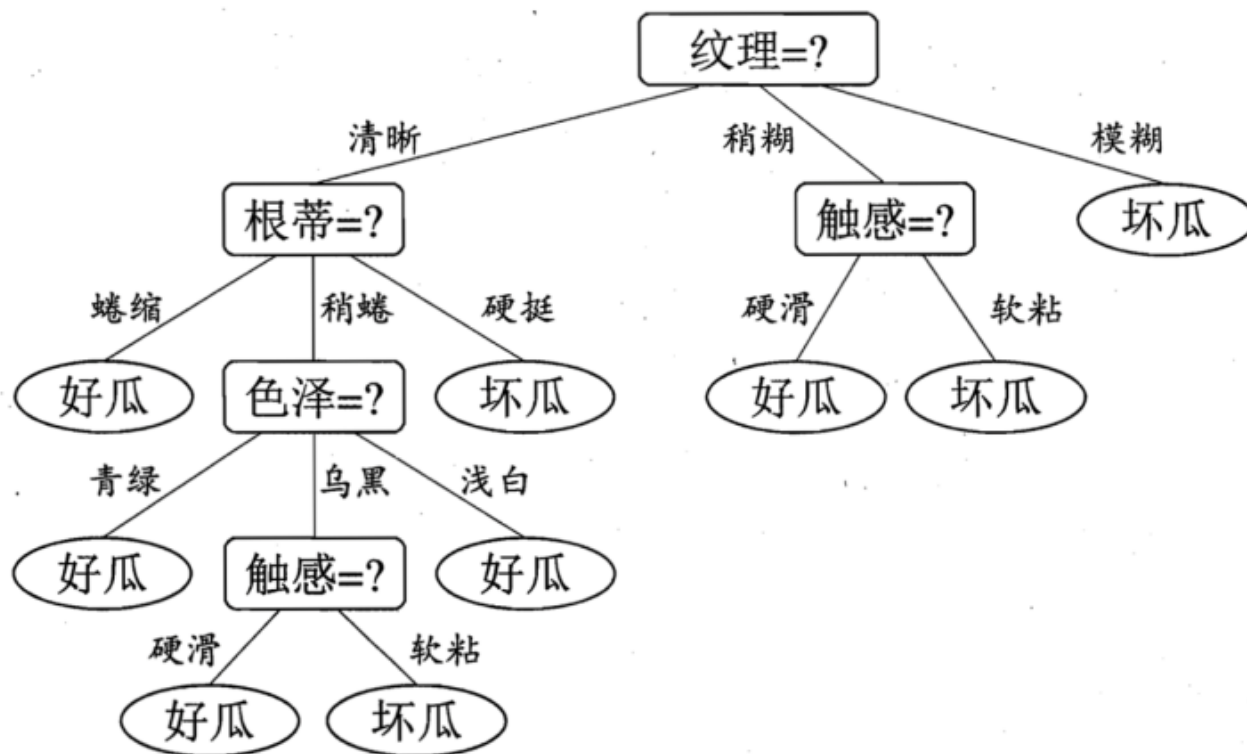
课程总览



决策树算法

主要思想

设定判定规则，根据判定结果不断分枝，形成决策树结构



决策树算法

算法流程

输入: 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$;

属性集 $A = \{a_1, a_2, \dots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

```
1: 生成结点 node;
2: if  $D$  中样本全属于同一类别  $C$  then
3:   将 node 标记为  $C$  类叶结点; return
4: end if
5: if  $A = \emptyset$  OR  $D$  中样本在  $A$  上取值相同 then
6:   将 node 标记为叶结点, 其类别标记为  $D$  中样本数最多的类; return
7: end if
8: 从  $A$  中选择最优划分属性  $a_*$ ;
9: for  $a_*$  的每一个值  $a_*^v$  do
10:  为 node 生成一个分支; 令  $D_v$  表示  $D$  中在  $a_*$  上取值为  $a_*^v$  的样本子集;
11:  if  $D_v$  为空 then
12:    将分支结点标记为叶结点, 其类别标记为  $D$  中样本最多的类; return
13:  else
14:    以 TreeGenerate( $D_v, A \setminus \{a_*\}$ ) 为分支结点
15:  end if
16: end for
```

输出: 以 node 为根结点的一棵决策树

例

x : 清晰、硬挺、乌黑、硬滑

y : 好瓜/坏瓜

A : 纹理、根蒂、色泽、触感


决策树的分支结点所包含的样本尽可能属于同一类别, 即结点的“纯度”尽量高。

决策树算法

信息熵

$$\text{Ent}(D) = - \sum_{k=1}^{|Y|} p_k \log_2 p_k$$

- ◆ 信息熵越小，纯度越高
- ◆ 平均分布取得最大值为 $\log_2 |Y|$



划分准则

- 信息增益 $\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$

对取值数目较多的类别有所偏好

- 信息增益率 $\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$ $\text{IV}(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$

- 基尼指数 $\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$ $\text{Gini}(D) = \sum_{k=1}^{|Y|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|Y|} p_k^2$

决策树算法

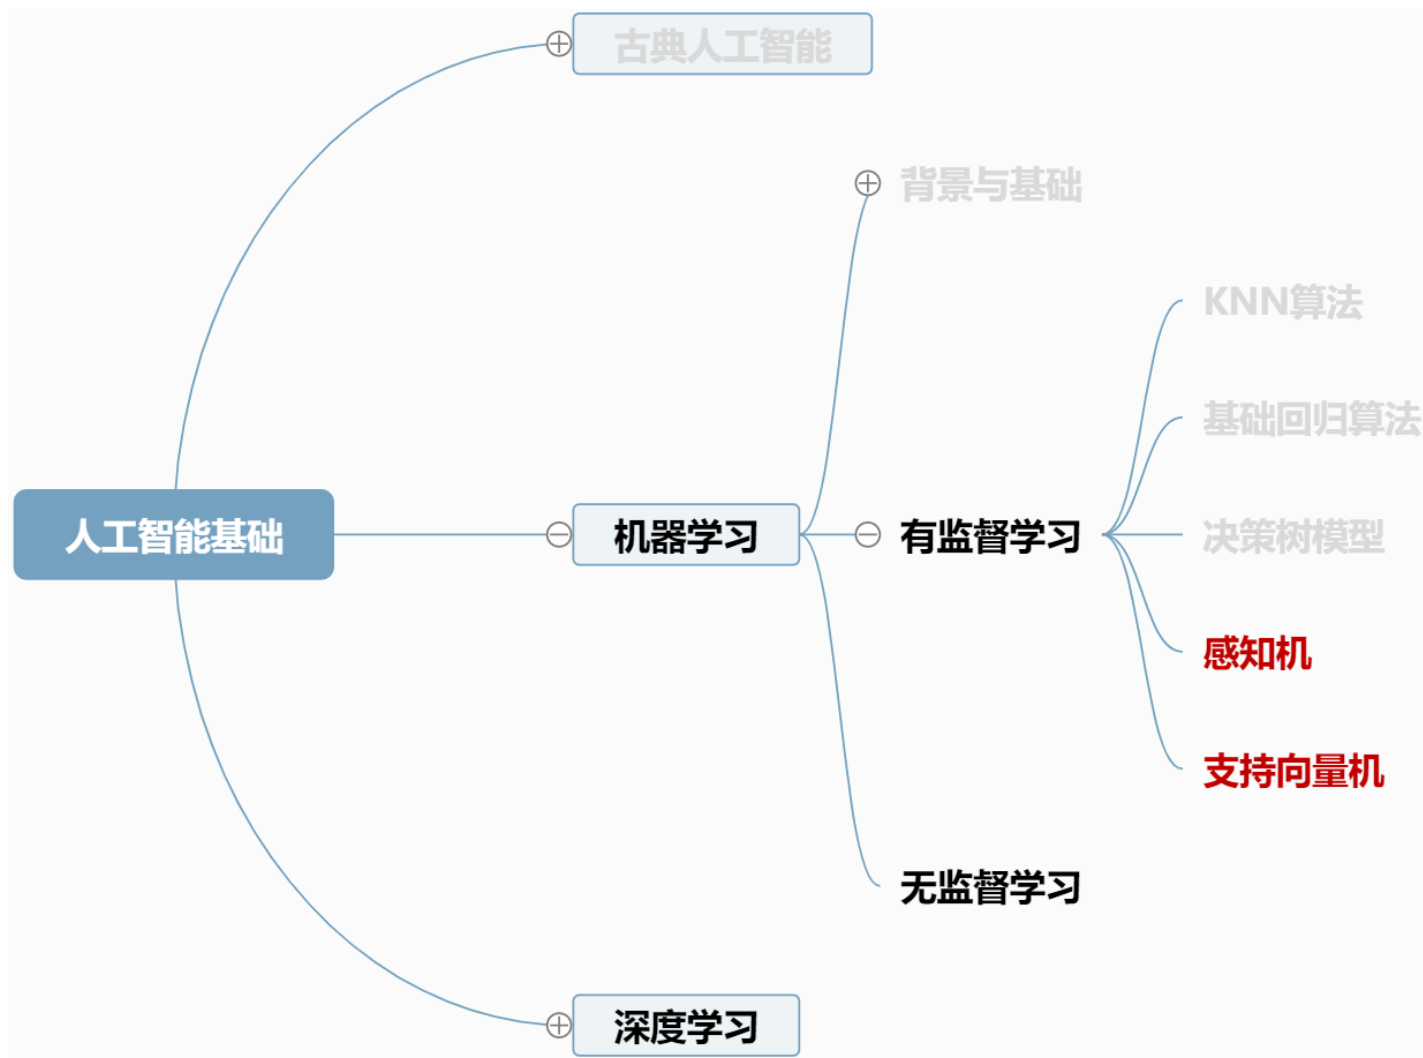
决策树剪枝

- ◆ 预剪枝：在决策树生成过程中进行剪枝
- ◆ 后剪枝：先生成一颗完整的决策树，再进行剪枝

适用性增强

- ◆ 连续属性值：二分法进行最优离散划分
- ◆ 缺失值处理：样本加权+概率划分
- ◆ 多变量决策树：一次性利用多个属性进行划分

本节概况





内容概要

- 内容回顾
- **感知机**
- 支持向量机
- 总结

感知机



诞生



The **perceptron** algorithm was invented in 1958 at the Cornell Aeronautical Laboratory by **Frank Rosenblatt**. The perceptron was intended to **be a machine, rather than a program**, and while its first implementation was in software for the IBM 704.

感知机

设计原理



- ◆ 接收神经信号:

$$x_{(1)}, x_{(2)}, x_{(3)}, \dots, x_{(D)}$$

- ◆ 内部汇总处理:

$$w_1 x_{(1)} + w_2 x_{(2)} + \dots + w_D x_{(D)} + b = \sum_{i=1}^D w_i x_{(i)} + b$$


- ◆ 激活输出:

$$y = \sigma \left(\sum_{i=1}^D w_i x_{(i)} + b \right)$$

感知机

激活函数

$$\sigma(z) = \text{sign}(z) = \begin{cases} 1, & z > 0 \\ 0, & z = 0 \\ -1, & z < 0 \end{cases}$$



感知机向量形式

$$y = \sigma \left(\sum_{i=1}^d w_i x_{(i)} + b \right) = \sigma(\mathbf{w}^T \mathbf{x} + b)$$

$$\mathbf{w} = (w_1, w_2, \dots, w_D)^T \in \mathbb{R}^D \quad \mathbf{x} = (x_{(1)}, x_{(2)}, \dots, x_{(D)})^T \in \mathbb{R}^D$$




感知机

几何意义

$$\sigma(\mathbf{w}^T \mathbf{x} + b) \quad \sigma(z) = \begin{cases} 1, & z > 0 \\ 0, & z = 0 \\ -1, & z < 0 \end{cases}$$

最终输出只与 $\mathbf{w}^T \mathbf{x} + b$ 的符号有关

$$\mathbf{w}, \mathbf{x} \in \mathbb{R}^2$$



感知机


二分类任务

◆ 训练数据: $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$ $\mathbf{x}_i \in \mathbb{R}^D$ $y_i \in \{-1, 1\}$

◆ 找到一组 (\mathbf{w}, b) 使得:


$$y_i \sigma(\mathbf{w}^T \mathbf{x}_i + b) = 1 \quad \longleftrightarrow \quad y_i (\mathbf{w}^T \mathbf{x}_i + b) > 0$$

◆ 找到一个 D 维超平面能够将 N 个训练数据完美分开



感知机

感知机学习



◆ 目标函数导出：

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0$$

$$i = 1, 2, \dots, N$$

$$\min_{\mathbf{w}, b} f(\mathbf{w}, b)$$

$$f(\mathbf{w}, b) = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i(\mathbf{w}^T \mathbf{x}_i + b)$$

感知机

感知机学习

◆ 目标函数

$$\min_{\mathbf{w}, b} f(\mathbf{w}, b) \quad f(\mathbf{w}, b) = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i(\mathbf{w}^T \mathbf{x}_i + b)$$

◆ 梯度下降

$$\begin{aligned} \nabla_b f &= - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} \nabla_b y_i(\mathbf{w}^T \mathbf{x}_i + b) \\ &= - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i(\nabla_b \mathbf{w}^T \mathbf{x}_i + \nabla_b b) \\ &= - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i(0 + 1) = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i \end{aligned}$$

感知机

感知机学习

◆ 目标函数

$$\min_{\mathbf{w}, b} f(\mathbf{w}, b) \quad f(\mathbf{w}, b) = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i(\mathbf{w}^T \mathbf{x}_i + b)$$

◆ 梯度下降

$$\nabla_{\mathbf{w}} f = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} (\text{ ? })$$

A

$$y_i(\mathbf{x}_i + b)$$

B

$$y_i \mathbf{x}_i$$

C

$$\mathbf{x}_i + b$$

D

$$y_i b$$

感知机

感知机学习

◆ 梯度

$$f(\mathbf{w}, b) = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i(\mathbf{w}^T \mathbf{x}_i + b)$$

$$\nabla_{\mathbf{w}} f = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} \nabla_{\mathbf{w}} y_i(\mathbf{w}^T \mathbf{x}_i + b)$$

$$= - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i(\nabla_{\mathbf{w}} \mathbf{w}^T \mathbf{x}_i + \nabla_{\mathbf{w}} b)$$

$$\mathbf{w}^T \mathbf{x}_i = \sum_{j=1}^d w_j x_{i(j)}$$

$$= - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i(\mathbf{x}_i + 0)$$

$$= - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i \mathbf{x}_i$$

感知机

感知机学习


◆ 梯度

$$\nabla_{\mathbf{w}} f = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i \mathbf{x}_i$$

$$\nabla_b f = - \sum_{y_i(\mathbf{w}^T \mathbf{x}_i + b) < 0} y_i$$

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} f$$

$$b \leftarrow b - \eta \nabla_b f$$



感知机

例子

◆ 假设给定训练集为

正类($y = +1$): $\{(1, 2), (1, 3), (2, 3), (2, 4)\}$

负类($y = -1$): $\{(3, 2), (4, 2), (2, 1), (3, 1)\}$

◆ 下面哪些参数对应的感知机可以对训练集正确分类 (多选)

A

$$\mathbf{w} = [-2, 1]$$
$$b = 2$$

B

$$\mathbf{w} = [1, 1]$$
$$b = -3$$

C

$$\mathbf{w} = [-1, 1]$$
$$b = 0$$

D


$$\mathbf{w} = [-1, 2]$$
$$b = -2$$

感知机

例子

正类($y = +1$): $\{(1, 2), (1, 3), (2, 3), (2, 4)\}$

负类($y = -1$): $\{(3, 2), (4, 2), (2, 1), (3, 1)\}$



感知机

例子

正类($y = +1$): $\{(1, 2), (1, 3), (2, 3), (2, 4)\}$

负类($y = -1$): $\{(3, 2), (4, 2), (2, 1), (3, 1)\}$

A

$$\mathbf{w} = [-2, 1]$$

$$b = 2$$

C

$$\mathbf{w} = [-1, 1]$$

$$b = 0$$

B


$$\mathbf{w} = [1, 1]$$

$$b = -3$$

D

$$\mathbf{w} = [-1, 2]$$

$$b = -2$$




内容概要


- 内容回顾
- 感知机
- **支持向量机**
- 总结

支持向量机

感知机的问题




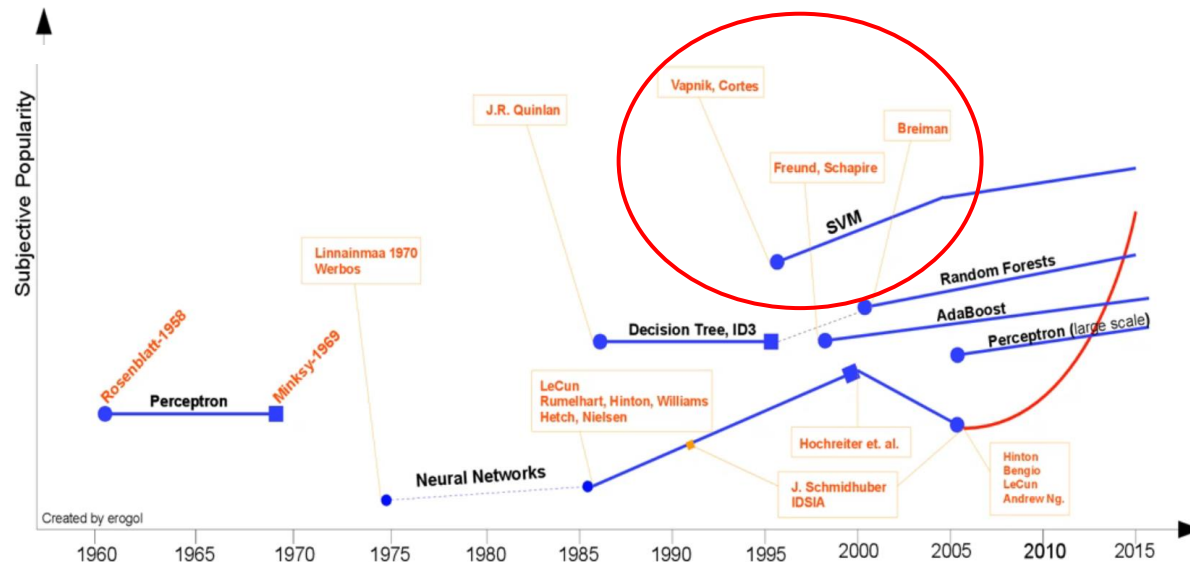
哪个分类超平面效果最好?



应选择“正中间”，容忍性好,鲁棒性高

支持向量机

支持向量机



In machine learning, **Support-Vector Machines (SVMs)** are supervised learning models with associated learning algorithms that analyze data for classification and regression analysis. Developed at AT&T Bell Laboratories by **Vladimir Vapnik** with colleagues in 1995. SVMs are one of the most robust prediction methods.

支持向量机

分离间隔最大化

分类超平面方程: $\mathbf{w}^T \mathbf{x} + b = 0$


点到超平面有向距离: $\frac{\mathbf{w}^T \mathbf{x} + b}{\|\mathbf{w}\|}$

训练数据: $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$

$$\mathbf{x}_i \in \mathbb{R}^D \quad y_i \in \{-1, 1\}$$

◆ 原始目标函数

$$\max_{\mathbf{w}, b} \min_i \frac{y_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$



支持向量机

问题转化

$$\max_{\tilde{\mathbf{w}}, \tilde{b}} \min_i \frac{y_i(\tilde{\mathbf{w}}^T \mathbf{x}_i + \tilde{b})}{\|\tilde{\mathbf{w}}\|}$$

对于任意超平面

$$\forall \gamma \neq 0$$

$$\tilde{\mathbf{w}}^T \mathbf{x} + \tilde{b} = 0$$



$$\frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x} + \frac{\tilde{b}}{\gamma} = 0$$

支持向量机

问题转化

$$\max_{\tilde{\mathbf{w}}, \tilde{b}} \min_i \frac{y_i(\tilde{\mathbf{w}}^T \mathbf{x}_i + \tilde{b})}{\|\tilde{\mathbf{w}}\|}$$

对于任意超平面

$$\forall \gamma \neq 0$$

$$\tilde{\mathbf{w}}^T \mathbf{x} + \tilde{b} = 0 \quad \longleftrightarrow \quad \frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x} + \frac{\tilde{b}}{\gamma} = 0$$

$$\exists \gamma \text{ 使得 } 1 = \min_i \left| \frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x}_i + \frac{\tilde{b}}{\gamma} \right|$$

此时间隔恰为 $\frac{2}{\|\mathbf{w}\|}$

支持向量机

问题转化

$$\max_{\tilde{\mathbf{w}}, \tilde{b}} \min_i \frac{y_i(\tilde{\mathbf{w}}^T \mathbf{x}_i + \tilde{b})}{\|\tilde{\mathbf{w}}\|}$$

对于任意超平面

$\forall \gamma \neq 0$


$$\tilde{\mathbf{w}}^T \mathbf{x} + \tilde{b} = 0$$



$$\frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x} + \frac{\tilde{b}}{\gamma} = 0$$

$$\exists \gamma \text{ 使得 } 1 = \min_i \left| \frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x}_i + \frac{\tilde{b}}{\gamma} \right|$$

此时间隔恰为 $\frac{2}{\|\mathbf{w}\|}$



支持向量机

问题转化

$$\max_{\tilde{\mathbf{w}}, \tilde{b}} \min_i \frac{y_i(\tilde{\mathbf{w}}^T \mathbf{x}_i + \tilde{b})}{\|\tilde{\mathbf{w}}\|}$$

对于任意超平面

$$\forall \gamma \neq 0$$

$$\tilde{\mathbf{w}}^T \mathbf{x} + \tilde{b} = 0$$



$$\frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x} + \frac{\tilde{b}}{\gamma} = 0$$

$$\exists \gamma \text{ 使得 } 1 = \min_i \left| \frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x}_i + \frac{\tilde{b}}{\gamma} \right|$$

此时间隔恰为 $\frac{2}{\|\mathbf{w}\|}$


令得 $\mathbf{w} = \frac{\tilde{\mathbf{w}}}{\gamma}$, $b = \frac{\tilde{b}}{\gamma}$, 则原问题转化为:

$$\max_{\mathbf{w}, b} \min_i \frac{y_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$



$$\max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|}$$

$$\text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad (i = 1, 2, \dots, N)$$



支持向量机

问题转化

$$\max_{\tilde{\mathbf{w}}, \tilde{b}} \min_i \frac{y_i(\tilde{\mathbf{w}}^T \mathbf{x}_i + \tilde{b})}{\|\tilde{\mathbf{w}}\|}$$

对于任意超平面

$$\forall \gamma \neq 0$$

$$\tilde{\mathbf{w}}^T \mathbf{x} + \tilde{b} = 0$$



$$\frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x} + \frac{\tilde{b}}{\gamma} = 0$$

$$\exists \gamma \text{ 使得 } 1 = \min_i \left| \frac{\tilde{\mathbf{w}}^T}{\gamma} \mathbf{x}_i + \frac{\tilde{b}}{\gamma} \right|$$

此时间隔恰为 $\frac{2}{\|\mathbf{w}\|}$


令得 $\mathbf{w} = \frac{\tilde{\mathbf{w}}}{\gamma}$, $b = \frac{\tilde{b}}{\gamma}$, 则原问题转化为:

$$\max_{\mathbf{w}, b} \min_i \frac{y_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$



$$\max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|}$$

$$\text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad (i = 1, 2, \dots, N)$$



支持向量机

对偶问题

$$\begin{array}{ccc} \max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|} & \longleftrightarrow & \min_{\mathbf{w}, b} \frac{\|\mathbf{w}\|^2}{2} \\ \text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 & & \text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \end{array}$$

◆ 拉格朗日乘子法

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ ($i = 1, \dots, N$) 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i (y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

- 第二步：构建对偶目标函数

$$\begin{array}{ccc} \max_{\boldsymbol{\alpha} \geq 0} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha}) & \longrightarrow & \begin{cases} \frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i = \mathbf{0} \\ \frac{\partial L}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0 \end{cases} \longrightarrow \begin{cases} \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ \sum_{i=1}^N \alpha_i y_i = 0 \end{cases} \\ \text{(若原优化问题为凸, 上方} & & \\ \text{优化问题与原问题等价)} & & \end{array}$$

支持向量机

对偶问题

◆ 拉格朗日乘子法

- 第三步：回代得出对偶目标函数

$$\begin{aligned} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^N \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ &= \frac{1}{2} \left(\sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \right)^T \left(\sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \right) - \sum_{i=1}^N \alpha_i \left(y_i \left(\left(\sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \right)^T \mathbf{x}_i + b \right) - 1 \right) \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \end{aligned}$$

第二步所得

$$\begin{cases} \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ \sum_{i=1}^N \alpha_i y_i = 0 \end{cases}$$

代入

对偶
问题

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0 \quad (i = 1, \dots, N) \end{aligned}$$

支持向量机

对偶问题

◆ 求解对偶问题

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i y_i \alpha_j y_j \mathbf{x}_i^T \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0 \quad (i = 1, \dots, N) \end{aligned}$$

- 第一步：按照规则选取一对需要更新的变量 α_i, α_j
- 第二步：固定其他变量，只针对 α_i, α_j 进行优化

$$\begin{aligned} \max_{\alpha_i, \alpha_j} \quad & \alpha_i + \alpha_j + \frac{1}{2} (\alpha_i^2 \mathbf{x}_i^T \mathbf{x}_i + \alpha_j^2 \mathbf{x}_j^T \mathbf{x}_j + 2\alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j) + Const \\ \text{s.t.} \quad & \alpha_j = \frac{1}{y_j} \left(\alpha_i y_i - \sum_{k \neq i, j} \alpha_k y_k \right), \quad \alpha_i, \alpha_j \geq 0 \end{aligned}$$

单变量凸二次优化
(课下推导练习)

- 第三步：重复上述操作，直到算法收敛

支持向量机

对偶问题

◆ 求解对偶问题

- 第四步：变量回代，得到原问题的最优解

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i$$

利用互补松弛条件，所有 $\alpha_i^* > 0$ 对应的 \mathbf{x}_i 为支持向量

$$b^* = -\frac{1}{2} \left(\text{mean}_{\alpha_i^* > 0, y_i = 1} \{ \mathbf{x}_i^T \mathbf{w}^* - 1 \} + \text{mean}_{\alpha_i^* > 0, y_i = -1} \{ \mathbf{x}_i^T \mathbf{w}^* + 1 \} \right)$$

◆ 测试

- 对于测试样本 \mathbf{z}

{	正类,	$\mathbf{z}^T \mathbf{w}^* + b^* > 0$
	负类,	$\mathbf{z}^T \mathbf{w}^* + b^* < 0$

支持向量机

例子

◆ 假设给定训练集为

正类($y = +1$): $\{(1, 2), (1, 3), (2, 3), (2, 4)\}$

负类($y = -1$): $\{(3, 2), (4, 2), (2, 1), (3, 1)\}$

◆ 下面哪个参数是SVM学习得到的结果（单选）

A

$$\mathbf{w} = [-2, 1]$$
$$b = 2$$

B

$$\mathbf{w} = [1, 1]$$
$$b = -3$$

C

$$\mathbf{w} = [-1, 1]$$
$$b = 0$$

D

$$\mathbf{w} = [-1, 2]$$
$$b = -2$$


支持向量机

线性不可分挑战

◆ 异或分类问题


正类($y = +1$): $\{(0, 1), (1, 0)\}$

负类($y = -1$): $\{(0, 0), (1, 1)\}$



◆ 线性可分适用范围

线性可分当且仅当正类样本的凸包与负类样本的凸包不存在交集




◆ 如何使SVM适用于非线性可分情况？

支持向量机

核方法

◆ 基本思想

通过构造特征变到
高维空间从而线性可分



◆ 引入特征映射 $\phi(\mathbf{x})$ 升维

一般维度越高，线性可分性越好，希望能够映射至无穷维

$$\phi(\mathbf{x}) \in \mathbb{R}^\infty$$

$$\mathbf{w}^T \phi(\mathbf{x}) + b = 0$$

如何求得一个无穷
维的线性超平面？

支持向量机

核方法

◆ 对偶表示法

$$\min_{\mathbf{w}, b} \frac{\|\mathbf{w}\|^2}{2}$$

s.t. $y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1$

原问题



$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i y_i \alpha_j y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

s.t. $\sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0 (i = 1, \dots, N)$

对偶问题

◆ 核函数

$$\phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) = \kappa(\mathbf{x}_i, \mathbf{x}_j)$$

$$\mathbf{K} = \begin{bmatrix} \kappa(\mathbf{x}_1, \mathbf{x}_1) & \kappa(\mathbf{x}_1, \mathbf{x}_2) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_N) \\ \kappa(\mathbf{x}_2, \mathbf{x}_1) & \kappa(\mathbf{x}_2, \mathbf{x}_2) & \cdots & \kappa(\mathbf{x}_2, \mathbf{x}_N) \\ \vdots & \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_N, \mathbf{x}_1) & \kappa(\mathbf{x}_N, \mathbf{x}_2) & \cdots & \kappa(\mathbf{x}_N, \mathbf{x}_N) \end{bmatrix} \in \mathbb{R}^{N \times N}$$

κ 被称为核函数，寻找合适的核函数往往比直接寻找 ϕ 更加方便

支持向量机

核方法

◆ 常用核函数

			名称	表达式	参数
无穷维	{	线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$		
		多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$		$d \geq 1$ 为多项式的次数
		高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$		$\delta > 0$ 为高斯核的带宽(width)
		拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$		$\delta > 0$
		Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$		\tanh 为双曲正切函数, $\beta > 0, \theta < 0$

◆ 选择适合的核函数取决于具体任务，需要用后验方式进行验证


支持向量机

容错策略

◆ 软间隔法

- 现实中很难保证数据线性可分; 即便找到某个核函数使其线性可分, 也很难断定是否是有过拟合造成的。

红色: 不满足约束的样本



- 引入“软间隔”的概念, 允许支持向量机在一些样本上不满足约束。

支持向量机

容错策略

◆ 软间隔法

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \end{aligned}$$

SVM原始优化问题



$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0 \quad (i = 1, \dots, N) \end{aligned}$$

ξ_i 为第*i*个训练样本的容错间隔

多分类问题

◆ 1 vs Others

对于每个类别训练一个SVM，将当前类别当做正类，其他类别当做负类

支持向量机

支持向量回归


- ◆ 软间隔法

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$


$$\text{s.t. } |\mathbf{w}^T \mathbf{x}_i + b - y_i| \geq \epsilon$$

- ◆ 本质上是使用了特殊损失函数的线性回归

- ◆ 核方法与软间隔法同样适用



感知机与神经网络



内容概要

- 内容回顾
- 感知机
- 支持向量机
- **总结**



总结

◆ 感知机

- 感知机的生物学原理
- 感知机的几何意义
- 感知机的求解

◆ 支持向量机

- 最大分类间隔
- 拉格朗日函数与对偶优化
- 核方法解决线性不可分问题
- 容错机制、多分类问题、支持向量回归
- 感知机与神经网络的关系



北京交通大学

BEIJING JIAOTONG UNIVERSITY

谢谢!

问题?